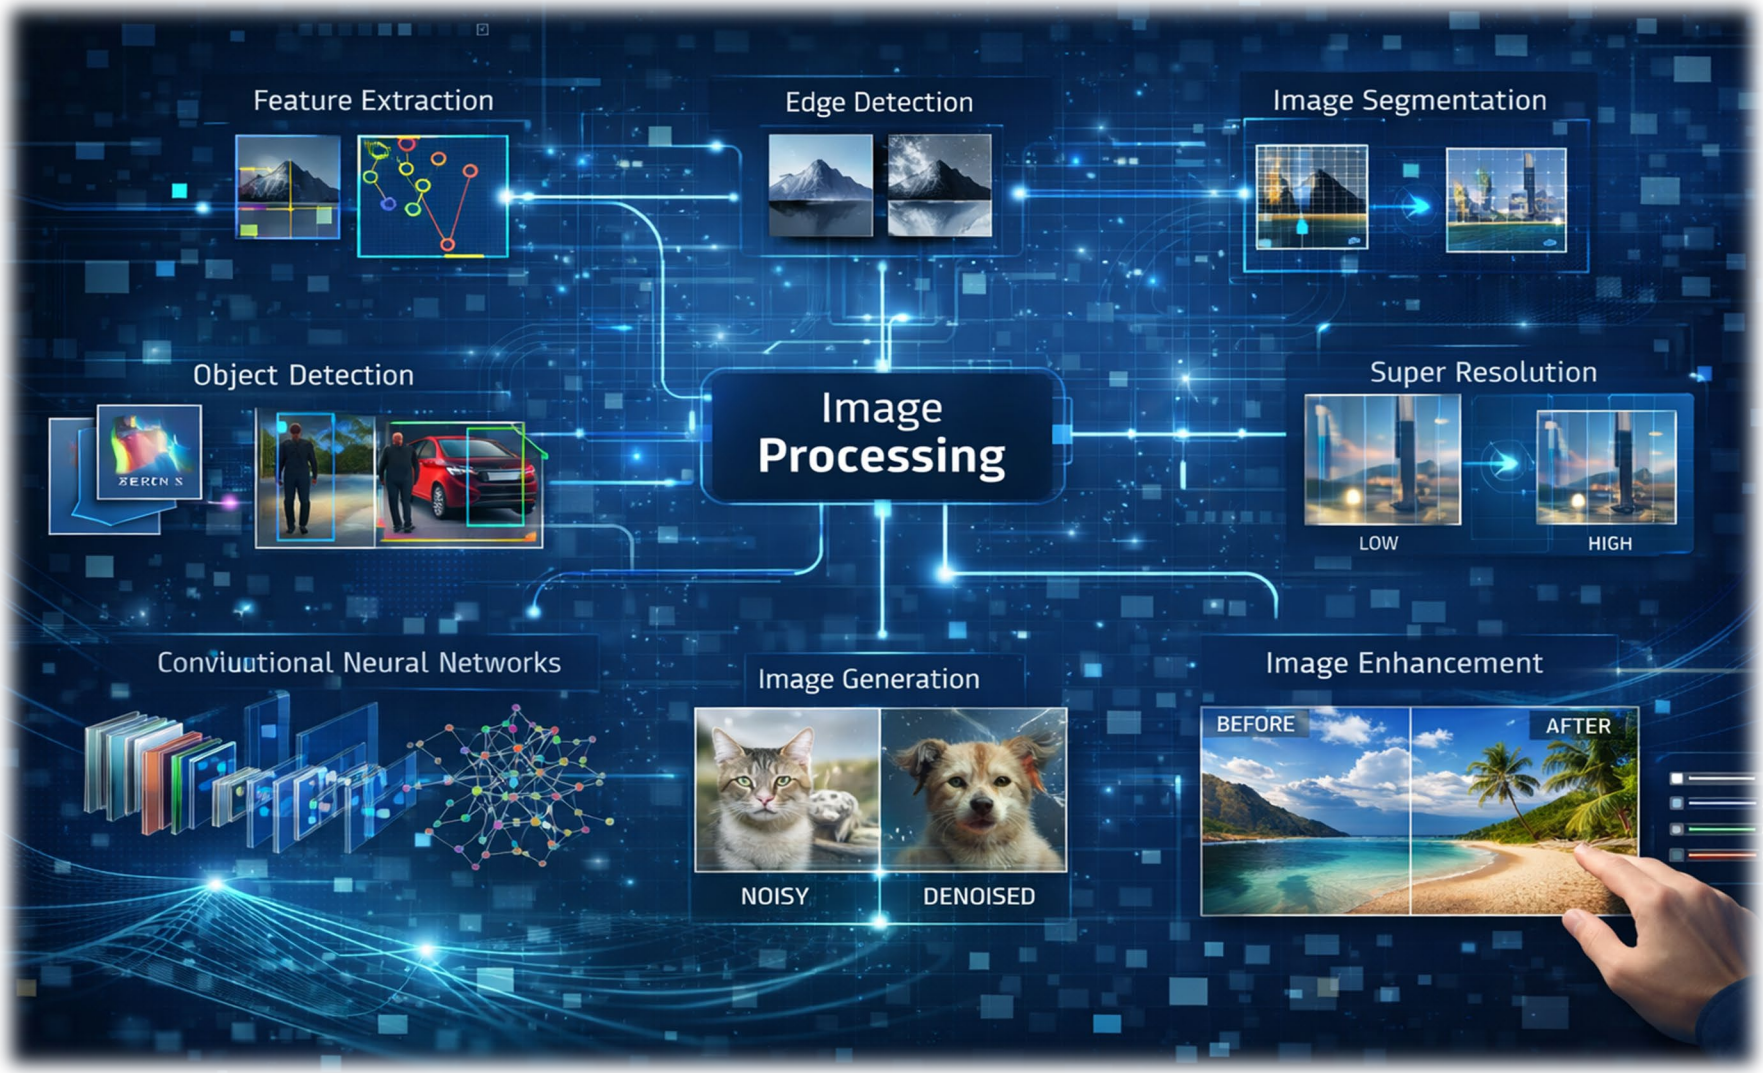
Feature Extraction
Edge Detection
Image Segmentation
Object Detection
Image Processing
Super Resolution
LOW
HIGH
Conviuutional Neural Networks
Image Generation
NOISY
DENOISED
Image Enhancement
BEFORE
AFTER

에지 검출

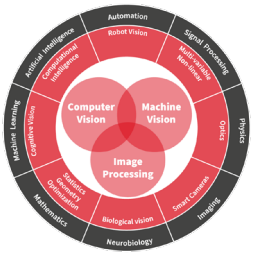
Automation
Robot Vision
Signal Processing
Artificial Intelligence
Computational Intelligence
Computer Vision
Machine Vision
Image Processing
Physics
Optics
Machine Learning
Cognitive Vision
Mathematics
Biological vision
Neurobiology
Intelligence

Interpolation(보간법)

방법	OpenCV 상수	동작 원리	특징	장점	단점
최근접 이웃 보간	**cv2.INTER_NEAREST**	가장 가까운 한 픽셀 값을 그대로 사용	가장 단순	매우 빠름 구현 쉬움	계단 현상 심함, 품질 낮음
양선형 보간	**cv2.INTER_LINEAR**	주변 4개 픽셀을 거리 비율로 가중 평균	가장 보편적	속도와 품질균형 좋음	약간 흐려질 수 있음
바이큐빅 보간	**cv2.INTER_CUBIC**	주변 16개 픽셀을 이용해 곡선 형태로 보간	더 부드럽고 자연스러움	확대 시 품질 좋음	계산량 큼, 약간의 오버슈트 가능
영역 기반 보간	**cv2.INTER_AREA**	영역 평균을 사용	축소에 강함	축소 시 aliasing 감소, 자연스러움	확대에는 큰 장점 없음
Lanczos 보간	**cv2.INTER_LANCZOS4**	sinc 계열 커널 기반, 넓은 주변 픽셀 참조	고품질	디테일 보존이 좋음	느림, 링잉(ringing) 가능

Interpolation(보간법)

```
import cv2
import matplotlib.pyplot as plt

# 이미지 읽기
img = cv2.imread("sample.jpg")
img_rgb = cv2.cvtColor(img, cv2.COLOR_BGR2RGB)

# 확대 결과
up_nearest = cv2.resize(img_rgb, None, fx=2, fy=2, interpolation=cv2.INTER_NEAREST)
up_linear = cv2.resize(img_rgb, None, fx=2, fy=2, interpolation=cv2.INTER_LINEAR)
up_cubic = cv2.resize(img_rgb, None, fx=2, fy=2, interpolation=cv2.INTER_CUBIC)
up_lanczos = cv2.resize(img_rgb, None, fx=2, fy=2, interpolation=cv2.INTER_LANCZOS4)

# 축소 결과
down_nearest = cv2.resize(img_rgb, None, fx=0.5, fy=0.5,
interpolation=cv2.INTER_NEAREST)
down_linear = cv2.resize(img_rgb, None, fx=0.5, fy=0.5, interpolation=cv2.INTER_LINEAR)
down_area = cv2.resize(img_rgb, None, fx=0.5, fy=0.5, interpolation=cv2.INTER_AREA)
down_lanczos = cv2.resize(img_rgb, None, fx=0.5, fy=0.5,
interpolation=cv2.INTER_LANCZOS4)
```

Interpolation(보간법)

```
# 확대 비교
plt.figure(figsize=(16, 8))

plt.subplot(2, 4, 1)
plt.imshow(up_nearest)
plt.title("Up - Nearest")
plt.axis("off")

plt.subplot(2, 4, 2)
plt.imshow(up_linear)
plt.title("Up - Linear")
plt.axis("off")

plt.subplot(2, 4, 3)
plt.imshow(up_cubic)
plt.title("Up - Cubic")
plt.axis("off")

plt.subplot(2, 4, 4)
plt.imshow(up_lanczos)
plt.title("Up - Lanczos4")
plt.axis("off")
```

```
# 축소 비교
plt.subplot(2, 4, 5)
plt.imshow(down_nearest)
plt.title("Down - Nearest")
plt.axis("off")

plt.subplot(2, 4, 6)
plt.imshow(down_linear)
plt.title("Down - Linear")
plt.axis("off")

plt.subplot(2, 4, 7)
plt.imshow(down_area)
plt.title("Down - Area")
plt.axis("off")

plt.subplot(2, 4, 8)
plt.imshow(down_lanczos)
plt.title("Down - Lanczos4")
plt.axis("off")

plt.tight_layout()
plt.show()
```

차례

4.1 에지 검출

4.2 캐니 에지

4.3 직선 검출

4.4 영역 분할

4.5 대화식 분할

4.6 영역 특징

Preview

■ 에지 검출과 영역 분할은 컴퓨터 비전 초창기부터 중요한 연구 주제

- 컴퓨터 비전 알고리즘이 사람 수준으로 분할할 수 있을까?

(a) 원래 영상 (b) 영역 영상(사람이 분할)

그림 4-1 영역 분할을 위한 BSDS 데이터셋

https://www2.eecs.berkeley.edu/Research/Projects/CS/vision/bsds/

Preview

■ 에지와 영역은 쌍대 문제지만 다른 접근방법 사용

- 에지는 특성이 다른 곳을 검출하지만 영역은 유사한 화소를 묶는 방법 사용

■ 사람은 의미 분할semantic segmentation에 능숙

- 사람은 머리 속에 기억된 물체 모델을 활용하여 의미 분할
- 이 장에서 공부하는 고전적인 방법은 의미 분할 불가능
- 딥러닝은 의미 분할이 가능해져 혁신을 일으킴(9장)

4.1 에지 검출

■ 에지 검출 알고리즘

- 물체 내부는 명암이 서서히 변하고 경계는 급격히 변하는 특성을 활용

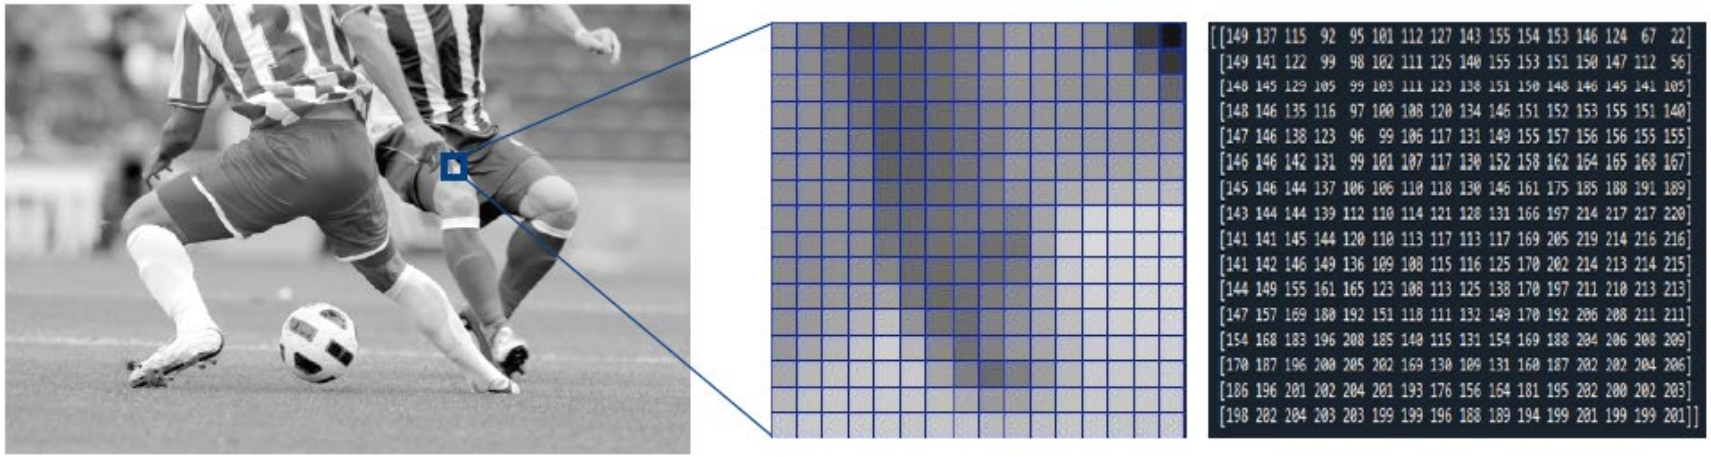

그림 4-2 명암 변화를 확인하기 위해 영상 일부를 확대

4.1.1 영상의 미분

■ 미분

- 변수 x가 미세하게 증가했을 때 함수 변화량을 측정하는 수학 기법

$$f'(x) = \lim_{\delta x \to 0} \frac{f(x+\delta x) - f(x)}{\delta x} \qquad (4.1)$$

- 미분을 디지털 영상에 적용하면,

$$f'(x) = \frac{f(x+\delta x) - f(x)}{\delta x} = f(x+1) - f(x) \qquad (4.2)$$

- 실제 구현은 필터 u로 컨볼루션 (u를 에지 연산자라 부름)

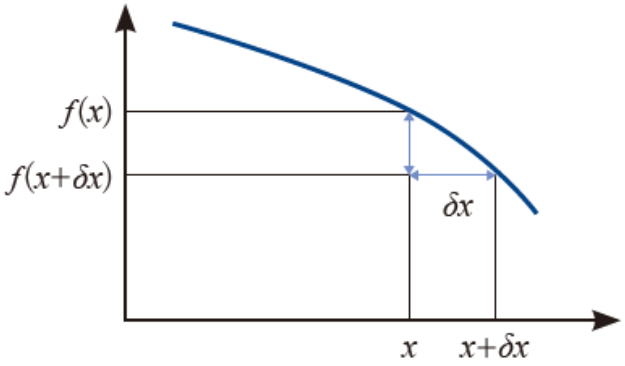

(a) 연속 함수의 미분

	0	1	2	3	4	5	6	7	8	9
원래 영상 f	2	2	2	2	2	2	5	5	5	5
에지 영상 f'	0	0	0	0	0	3	0	0	0	-

필터 $u=$ | -1 | 1 | 로 컨볼루션

(b) 디지털 영상의 미분(필터 u로 컨볼루션)

그림 4-3 연속 함수와 디지털 영상의 미분

4.1.2 에지 연산자

■ 현실 세계의 램프 에지

- 명암이 몇 화소에 걸쳐 변함

■ 1차 미분과 2차 미분

두꺼운 에지로 인해 위치찾기 문제 발생

	0	1	2	3	4	5	6	7	8	9	0	1
원래 영상 f	3	3	3	3	5	7	7	7	7	3	3	3

필터 $u=$ | -1 | 1 | 로 컨볼루션

1차 미분 f'	0	0	0	2	2	0	0	0	-4	0	0	-

필터 $u=$ | -1 | 1 | 로 컨볼루션

2차 미분 f''	0	0	2	0	-2	0	0	-4	4	0	-	-

그림 4-4 현실 세계에서 발생하는 램프 에지

4.1.2 에지 연산자

■ 2차 미분

$$
\begin{aligned}
f''(x) &= \frac{f'(x)-f'(x-\delta)}{\delta} = f'(x)-f'(x-1) \\
&= \left(f(x+1)-f(x)\right)-\left(f(x)-f(x-1)\right) \\
&= f(x+1)-2f(x)+f(x-1)
\end{aligned}
\tag{4.3}
$$

이 식을 구현하는 필터는

1	-2	1

4.1.2 에지 연산자

■ 에지 검출

- 1차 미분에서 봉우리 찾기
- 2차 미분에서 영교차zero-crossing 찾기

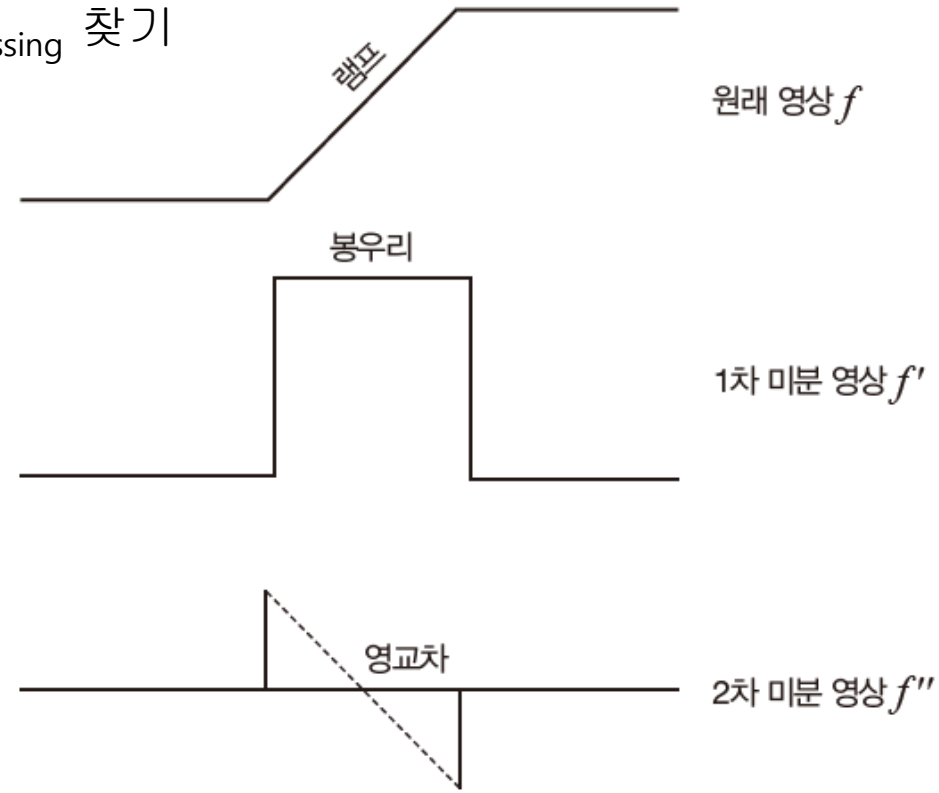

그림 4-5 램프 에지에서 발생하는 봉우리와 영교차

4.1.2 에지 연산자

■ 1차 미분에 기반한 에지 연산자

- 실제 영상에 있는 잡음을 흡수하기 위해 크기가 2인 필터를 크기 3으로 확장

$$f_x'(y,x) = f(y,x+1) - f(y,x-1)$$
$$f_y'(y,x) = f(y+1,x) - f(y-1,x) \qquad (4.4)$$

이 식을 구현하는 필터는 $u_x = \begin{bmatrix} -1 & 0 & 1 \end{bmatrix}$ 와 $u_y = \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}$

- 또한 1차원을 2차원으로 확장

$$u_x = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix} \quad u_y = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix}$$

(a) 프레윗(Prewitt) 연산자

$$u_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \quad u_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}$$

(b) 소벨(Sobel) 연산자

그림 4-6 에지 연산자

4.1.2 에지 연산자

■ 에지 강도와 에지 방향

에지 강도: $s(y,x)=\sqrt{f_x^{'}(y,x)^2+f_y^{'}(y,x)^2}$

그레이디언트 방향: $d(y,x)=\arctan\left(\dfrac{f_y^{'}(y,x)}{f_x^{'}(y,x)}\right)$ (4.5)

에지 알고리즘(1차 미분 기반)

알고리즘	미분 방식 / 핵심 아이디어	마스크	장점	단점	노이즈 민감도	방향 정보	계산량	결과 특징	적합한 용도
Roberts	대각선 방향 차분으로 1차 미분 근사	2×2	매우 단순, 매우 빠름	노이즈에 약함, 방향 표현이 거침, 작은 마스크라 불안정	매우 높음	있음(대각선 중심)	매우 작음	날카롭지만 불안정한 에지	아주 기초적 예제, 단순 실험
Prewitt	수평/수직 방향 차분, 단순 평균 포함	3×3	구조가 단순, 이해 쉬움, Roberts보다 안정적	Sobel보다 잡음 억제 약함	높음	있음	작음	비교적 단순한 에지	교육용, 기본 에지 검출
Sobel	중심 가중치를 둔 수평/수직 1차 미분	3×3	Prewitt보다 안정적, 가장 널리 사용, 노이즈 억제 효과 더 좋음	아주 정밀한 방향 추정은 한계	중간	있음	작음~중간	선명하고 안정적인 에지	일반적인 영상 에지 검출
Scharr	Sobel 개선형, 회전 대칭성과 방향 정확도 향상	3×3	Sobel보다 방향 정확도 우수, 미세 방향 변화에 강함	교육용으로는 덜 직관적, Sobel보다 덜 친숙	중간	매우 좋음	중간	더 정확한 gradient	정밀한 기울기 계산
Canny	Gaussian smoothing + gradient + 비최대 억제 + 이중 임계값 + 히스테리시스	다단계	잡음에 강함, 얇고 선명한 에지, 끊김 적음, 품질 우수	계산량 큼, 파라미터 조절 필요	낮음(전처리 포함 시)	있음	큼	매우 깔끔한 1픽셀급 에지	실전용, 고품질 에지 검출

에지 알고리즘(2차 미분 기반)

알고리즘	핵심 아이디어	대표 형태	장점	단점	노이즈 민감도	방향 정보	계산량	결과 특징	적합한 용도
Laplacian	x, y 방향 2차 미분의 합	3×3 마스크	방향에 무관하게 에지 검출 가능, 매우 간단	노이즈에 매우 민감, 단독 사용 시 거친 결과	매우 높음	거의 없음	작음	양/음 반응이 함께 나타남	기본 2차 미분 실험, 개념 이해
LoG	Gaussian으로 스무딩 후 Laplacian 적용	Gaussian + Laplacian	Laplacian의 노이즈 문제 완화, 영교차 기반 에지 검출 가능	σ와 커널 크기 선택 중요, 계산량 증가	중간	거의 없음	중간~큼	부드럽고 안정적인 영교차	정교한 에지 위치 검출
DoG	서로 다른 두 Gaussian 결과의 차이로 LoG 근사	두 Gaussian의 차	LoG보다 효율적, 멀티스케일 분석 가능	근사 방식이라 파라미터 설정에 따라 결과 차이	중간	거의 없음	중간	스케일 변화에 민감한 구조 검출	특징 검출, 멀티스케일 분석

4.1.2 에지 연산자

이들 맵은 음수를 포함하며
실수이므로 32비트 실수 형
cv.CV_32F로 지정할 필요

[예시 4-1] 소벨 연산자 적용 과정

[그림 4-7]은 대각선을 기준으로 위쪽은 3, 아래쪽은 1인 가상의 영상에 소벨 에지 연산자를 적용하는 과정을 예시한다. 회색으로 표시한 (3,4) 화소에 대한 자세한 계산 과정을 설명한다.

	0	1	2	3	4	5	6	7
0	1	3	3	3	3	3	3	3
1	1	1	3	3	3	3	3	3
2	1	1	1	3	3	3	3	3
3	1	1	1	1	3	3	3	3
4	1	1	1	1	1	3	3	3
5	1	1	1	1	1	1	3	3
6	1	1	1	1	1	1	1	3
7	1	1	1	1	1	1	1	1

$$f_y'(3,4) = -6,\ f_x'(3,4) = 6$$

$$s(3,4) = \sqrt{6^2 + (-6)^2} = 8.485$$

$$d(3,4) = \arctan\left(\frac{-6}{6}\right) = -45°$$

→ f_x'와 f_y'

→ 그레이디언트 방향

⇢ 에지 방향

그림 4-7 소벨 연산자 적용 사례

4.1.2 에지 연산자

프로그램 4-1 소벨 에지 검출(Sobel 함수 사용)하기

```
01  import cv2 as cv
02
03  img=cv.imread('soccer.jpg')
04  gray=cv.cvtColor(img,cv.COLOR_BGR2GRAY)
05
06  grad_x=cv.Sobel(gray,cv.CV_32F,1,0,ksize=3)      # 소벨 연산자 적용
07  grad_y=cv.Sobel(gray,cv.CV_32F,0,1,ksize=3)
08
09  sobel_x=cv.convertScaleAbs(grad_x)               # 절댓값을 취해 양수 영상으로 변환
10  sobel_y=cv.convertScaleAbs(grad_y)
11
12  edge_strength=cv.addWeighted(sobel_x,0.5,sobel_y,0.5,0)   # 에지 강도 계산
13
14  cv.imshow('Original',gray)
15  cv.imshow('sobelx',sobel_x)
16  cv.imshow('sobely',sobel_y)
17  cv.imshow('edge strength',edge_strength)
18
19  cv.waitKey()
20  cv.destroyAllWindows()
```

cv.CV_8U(numpy의 uint8)로 변환
0보다 작으면 0, 255보다 크면 255로 바꿈

addWeighted(i1,a,i2,b,c)는 i1*a+i2*b+c를 계산
i1과 i2가 같은 데이터 형이면 결과는 같은 데이터 형, 다르면 오류 발생
i1과 i2가 CV_8U인데 계산 결과가 255를 넘으면 255를 기록

4.1.2 에지 연산자

sobel_x

sobel_y

edge_strength

4.2 캐니 에지

■ 에지 검출을 최적화 문제로 품

- 최소 오류율, 위치 정확도, 한 두께라는 세 가지 기준으로 목적 함수 정의
- 한 두께를 위해 비최대 억제non-maximum suppression(NMS) 적용

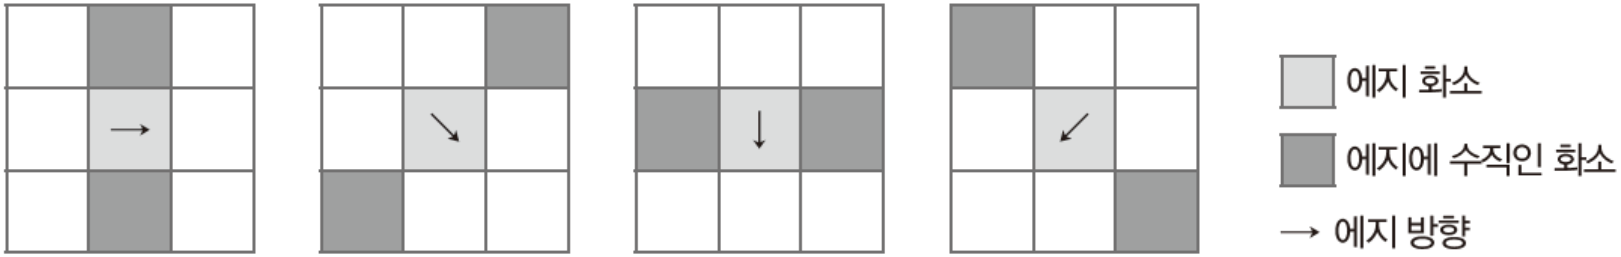

그림 4-8 비최대 억제

- 거짓 긍정을 줄이기 위해 두 개의 이력 임계값 사용
  - 에지 강도가 T_{high} 이상인 에지에서 에지 추적 시작
  - 이후 추적은 T_{low} 이상인 에지를 대상으로 진행

4.2 캐니 에지

프로그램 4-2 캐니 에지 실험하기

```
01  import cv2 as cv
02
03  img=cv.imread('soccer.jpg')        # 영상 읽기
04
05  gray=cv.cvtColor(img,cv.COLOR_BGR2GRAY)
06
07  canny1=cv.Canny(gray,50,150)       # Tlow=50, Thigh=150으로 설정
08  canny2=cv.Canny(gray,100,200)      # Tlow=100, Thigh=200으로 설정
09
10  cv.imshow('Original',gray)
11  cv.imshow('Canny1',canny1)
12  cv.imshow('Canny2',canny2)
13
14  cv.waitKey()
15  cv.destroyAllWindows()
```

4.2 캐니 에지

물체 경계와 그림자 에지를 구별하지 못하는 한계
사람은 물체의 3차원 모델과 겉모습 모델appearance model을
사용하여 의미적으로 검출

4.3 직선 검출

- 에지를 명시적으로 연결하여 경계선을 찾고 직선으로 변환
  - 이후 처리 단계인 물체 표현이나 인식에 유리

4.3.1 경계선 찾기

■ 8-연결된 에지 화소를 연결해 경계선contour 구성

	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
0																
1			○				○	○	○							
2		○								○						
3		○							○					○		
4		○						○					○		○	
5		○			○			○							○	
6			○	○									○	○		
7																

경계선1: (1,2)(2,1)(3,1)(4,1)(5,1)(6,2)(6.3)(5,4)
경계선2: (1,6)(1,7)(1,8)(2,9)(3,8)(4,7)(5,7)
경계선3: (4,12)(3,13)(4,14)(5,14)(6,13)(6,12)

그림 4-9 에지 맵에서 경계선 찾기

4.3.1 경계선 찾기

프로그램 4-3 에지 맵에서 경계선 찾기

```
import cv2 as cv
import numpy as np

img=cv.imread('soccer.jpg')            # 영상 읽기
gray=cv.cvtColor(img,cv.COLOR_BGR2GRAY)
canny=cv.Canny(gray,100,200)

contour,hierarchy=cv.findContours(canny,cv.RETR_LIST,cv.CHAIN_APPROX_NONE)

lcontour=[]
for i in range(len(contour)):
    if contour[i].shape[0]>100:        # 길이가 100보다 크면
        lcontour.append(contour[i])

cv.drawContours(img,lcontour,-1,(0,255,0),3)

cv.imshow('Original with contours',img)
cv.imshow('Canny',canny)

cv.waitKey()
cv.destroyAllWindows()
```

이 매개변수를 통해
여러 가지 근사 방법 제공

시작점으로 돌아올 때까지 추적하므로
실제로는 50보다 크면

4.3.1 경계선 찾기

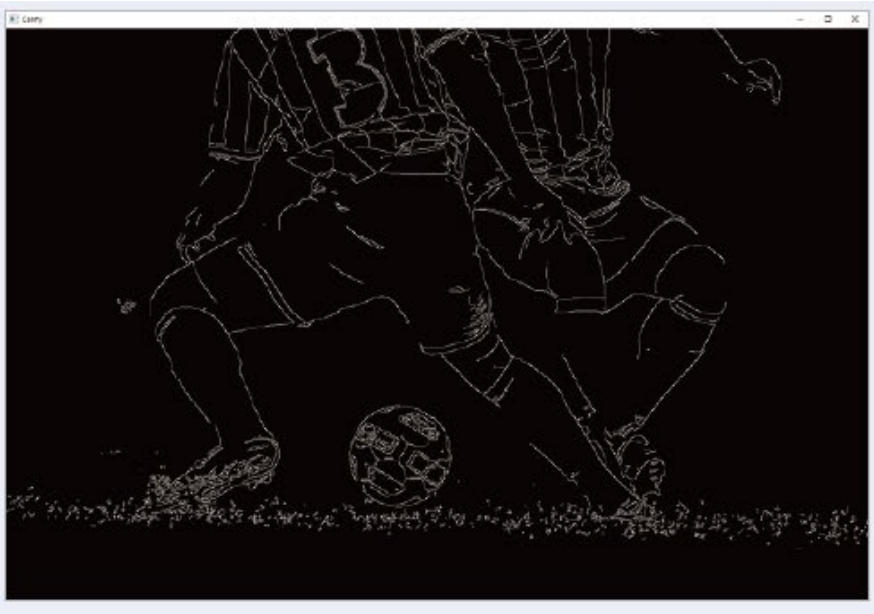

4.3.2 허프 변환

■ **허프 변환은 끊긴 에지를 모아 직선 또는 원 등을 검출**

■ **직선 검출의 원리**

- 각각의 점 (y_i, x_i)에 대해 (b, a) 공간에 직선 $b = -ax_i + y_i$를 그림
- (b, a) 공간에서 직선이 만나는 점을 절편과 기울기로 취함. 만나는 점은 투표로 알아냄

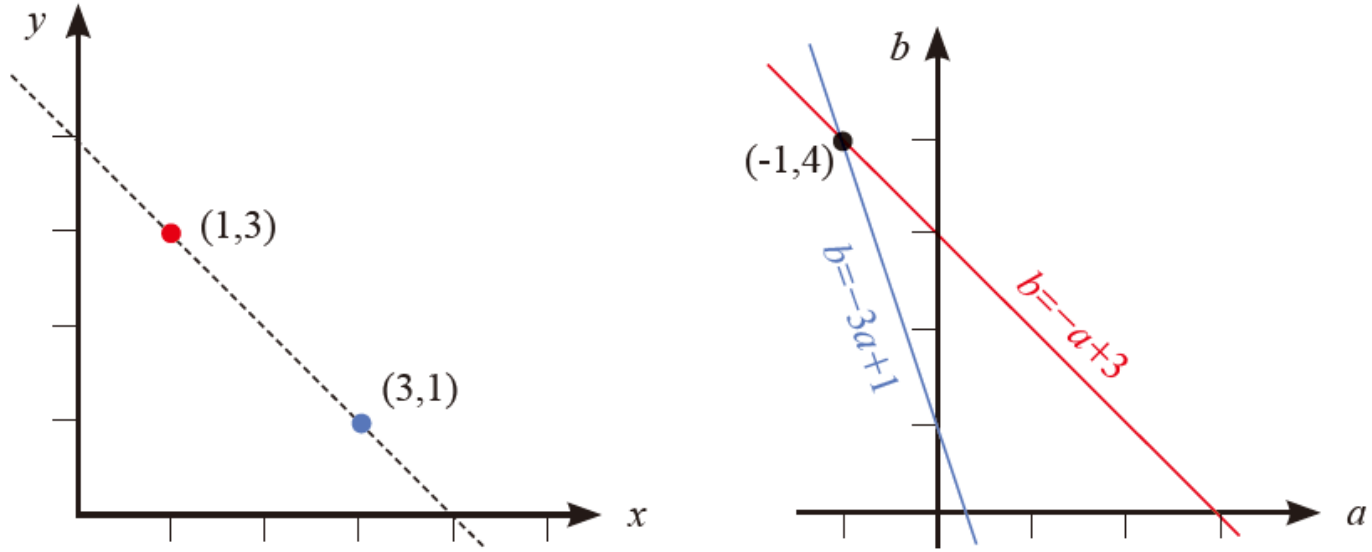

(a) (y, x)로 표현되는 영상 좌표 (b) (b, a)로 표현되는 공간으로 매핑

그림 4-10 허프 변환의 원리

4.3.2 허프 변환

■ 구현

- (b, a) 공간을 이산화하고 누적 배열 만들어 투표를 기록
- 직선은 자신이 지나는 칸에 1만큼씩 투표
- 다수 표를 얻은 점을 결정할 때 비최대 억제 적용하여 지역 최대점 찾음

0	1	0	0	0	0	0	0
0	2	2	0	1	3	0	0
0	3	5	3	2	0	0	0
0	2	4	2	6	7	0	0
0	2	3	3	5	8	6	0
0	1	0	0	0	4	5	3

그림 4-11 비최대 억제로 찾은 극점 2개

- 극좌표에서 정의된 직선의 방정식 사용 (기울기가 무한대인 경우 대처)

$$x\sin(\theta) + y\cos(\theta) = \rho \qquad (4.6)$$

4.3.2 허프 변환

■ 원 검출을 위한 허프 변환은 **3**차원 누적 배열 사용

$$(x-a)^2+(y-b)^2=r^2 \qquad (4.7)$$

4.3.2 허프 변환

프로그램 4-4 허프 변환을 이용해 사과 검출하기

```
import cv2 as cv

img=cv.imread('apples.jpg')
gray=cv.cvtColor(img,cv.COLOR_BGR2GRAY)

apples=cv.HoughCircles(gray,cv.HOUGH_GRADIENT,1,200,param1=150,param2=20,
                       minRadius=50,maxRadius=120)

for i in apples[0]:
    cv.circle(img,(int(i[0]),int(i[1])),int(i[2]),(255,0,0),2)

cv.imshow('Apple detection',img)

cv.waitKey()
cv.destroyAllWindows()
```

4.3.3 RANSAC

■ 허프 변환과 최소평균제곱오차LMSE; Least Mean Squared Error

- 강인하지 않은 추정 기법
- 아웃라이어를 걸러내는 기능이 전혀 없음 (모든 점에 같은 기회 부여)

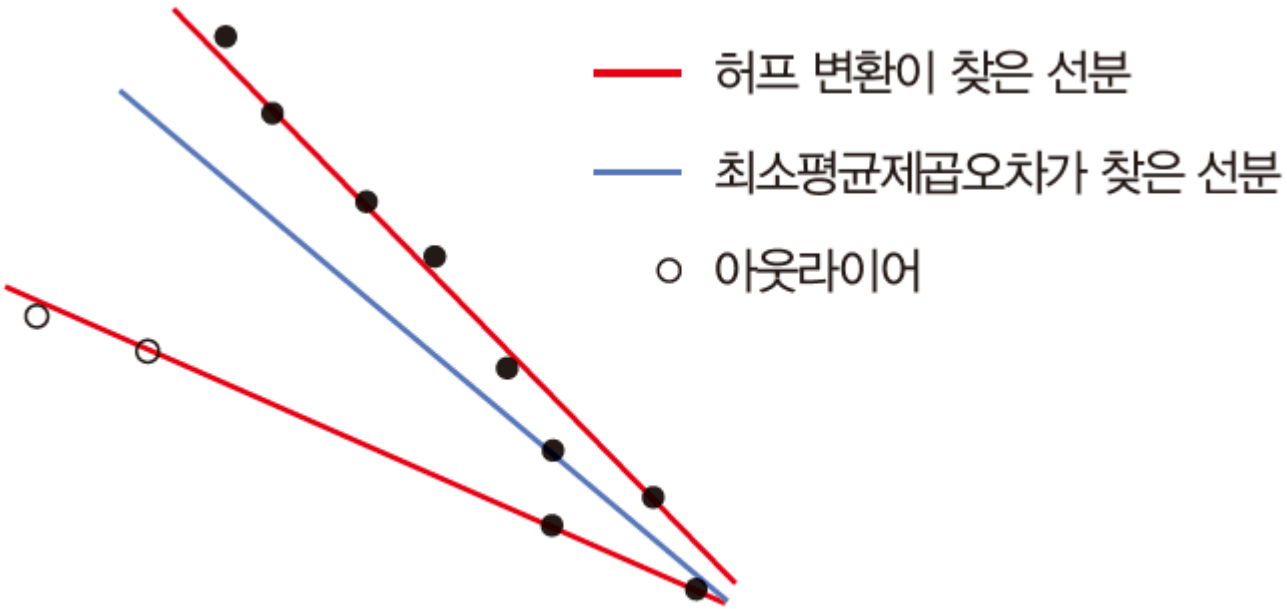

그림 4-12 강인하지 않은 기법의 선분 추정

4.3.3 RANSAC

■ 강인한robust 추정 기법

- 예) 물건의 길이를 5번 측정한 결과 {16,1,1,1,1}에 평균 적용하면 4, 중앙값 median 적용하면 1. 중앙값은 강인한 추정 기법

■ RANSAC은 강인한 추정 기법

- RANSAC은 구체적인 문제에 두루 활용할 수 있는 메타 알고리즘
- 난수를 생성하여 추정하는 일을 충분히 많이 반복하고 가장 신뢰할 수 있는 값 선택

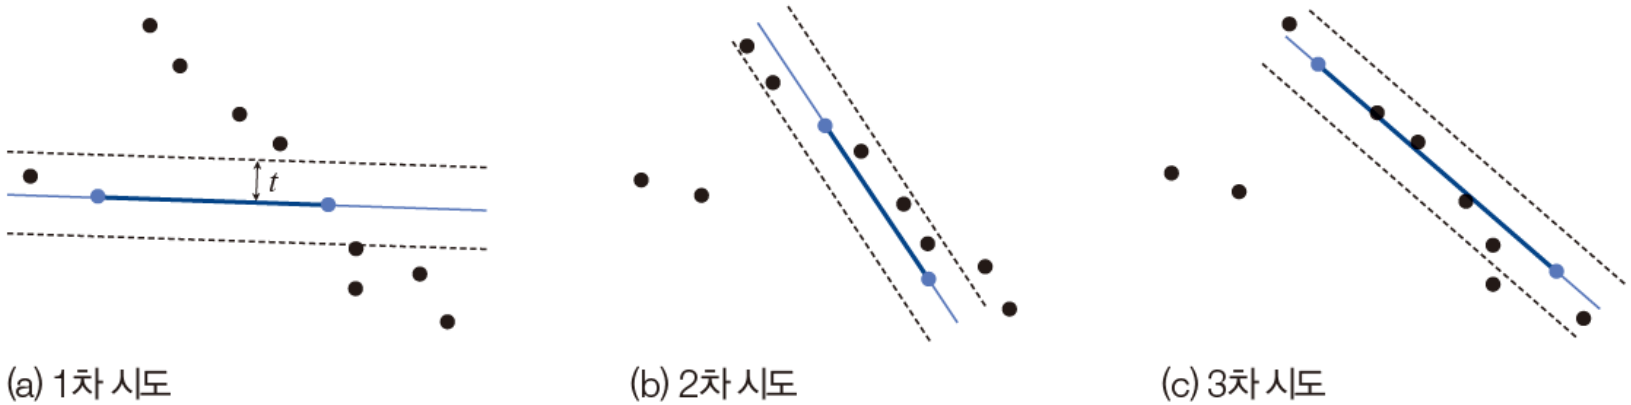

그림 4-13 RANSAC으로 선분 추정(1차, 2차, 3차, 4차, … 시도를 반복)

4.4 영역 분할

■ **영역 분할region segmentation은 물체가 점유한 영역을 구분하는 작업**

- 사람은 물체의 3차원 모델을 사용하고 주의 집중을 적용하여 의미 분할 수행
- 4장은 딥러닝 이전의 고전 기법을 다룸. 명암 또는 컬러만 보고 영역을 결정하기 때문에 의미 분할 불가능

4.4.1 배경이 단순한 영상의 영역 분할

■ 단순한 영상의 예

- 스캔한 책 영상 또는 컨베이어 벨트 위를 흐르는 물체의 영상

■ 영역 분할 알고리즘

- 이진화 알고리즘 (여러 임계값을 사용하는 오츄 알고리즘, 군집화 알고리즘 등) 적용
- 워터셰드 알고리즘 적용

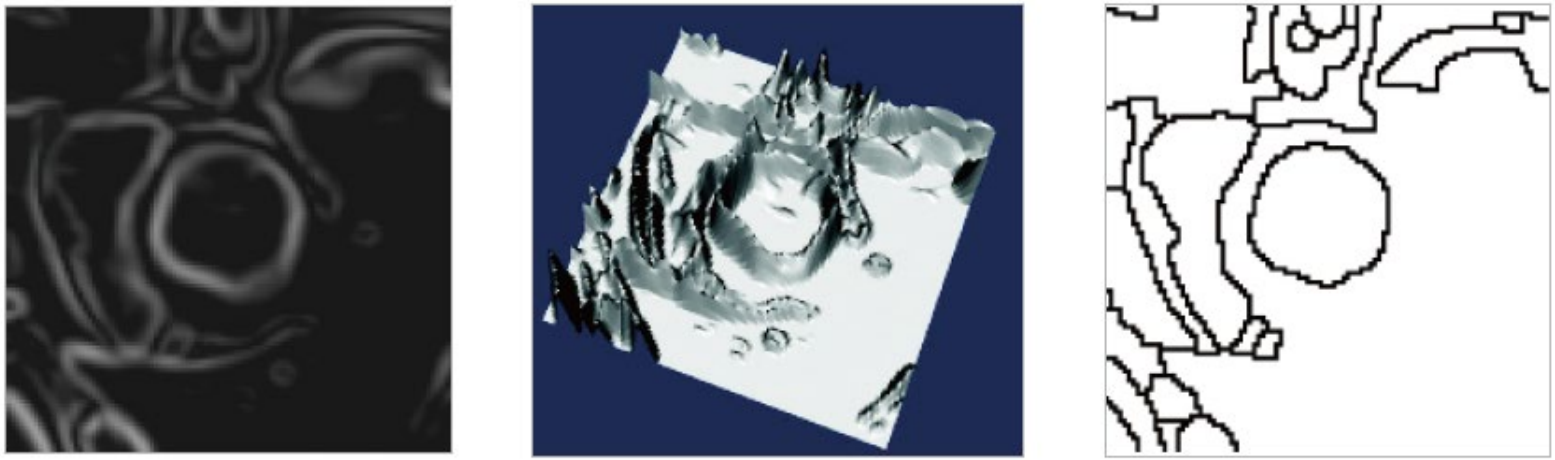

(a) 에지 강도 맵 (b) 지형으로 간주 (c) 워터셰드

그림 4-14 워터셰드 분할 알고리즘[Cousty2007]

4.4.2 슈퍼 화소 분할

- 슈퍼 화소는 화소보다 크지만 물체보다 작은 자잘한 영역으로 과잉 분할
- **SLIC**$_{\text{simple linear iterative clustering}}$ 알고리즘
  - k-평균 군집화와 비슷하게 동작 (화소 할당 단계와 군집 중심 갱신하는 단계를

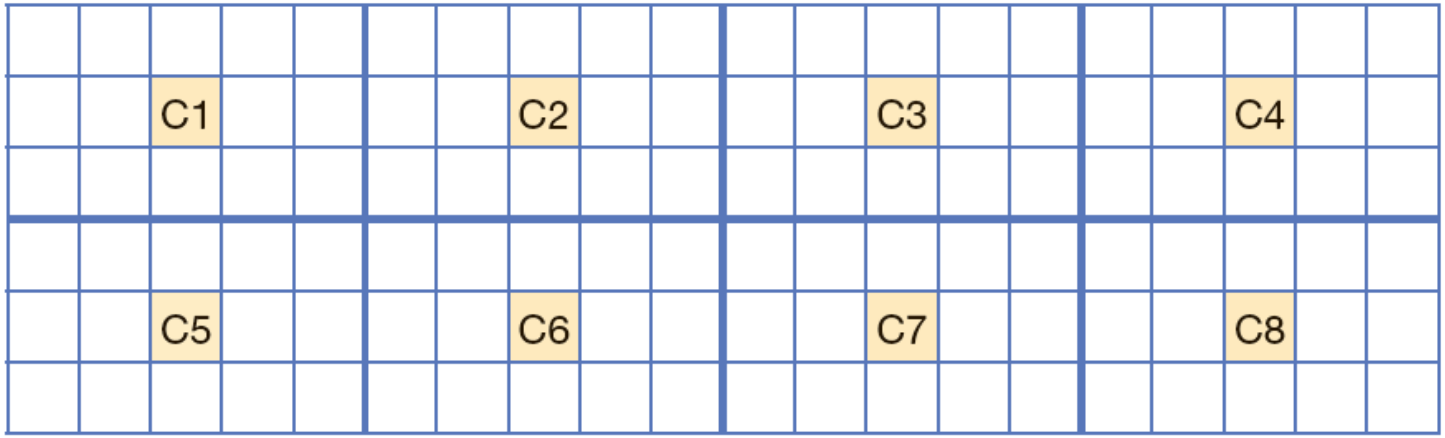

그림 4-15 SLIC 알고리즘의 초기 군집 중심

4.4.2 슈퍼 화소 분할

프로그램 4-5 SLIC 알고리즘으로 입력 영상을 슈퍼 화소 분할하기

```
01  import skimage
02  import numpy as np
03  import cv2 as cv
04
05  img=skimage.data.coffee()
06  cv.imshow('Coffee image',cv.cvtColor(img,cv.COLOR_RGB2BGR))
07
08  slic1=skimage.segmentation.slic(img,compactness=20,n_segments=600)
09  sp_img1=skimage.segmentation.mark_boundaries(img,slic1)
10  sp_img1=np.uint8(sp_img1*255.0)
11
12  slic2=skimage.segmentation.slic(img,compactness=40,n_segments=600)
13  sp_img2=skimage.segmentation.mark_boundaries(img,slic2)
14  sp_img2=np.uint8(sp_img2*255.0)
15
16  cv.imshow('Super pixels (compact 20)',cv.cvtColor(sp_img1,cv.COLOR_RGB2BGR))
17  cv.imshow('Super pixels (compact 40)',cv.cvtColor(sp_img2,cv.COLOR_RGB2BGR))
18
19  cv.waitKey()
20  cv.destroyAllWindows()
```

4.4.2 슈퍼 화소 분할

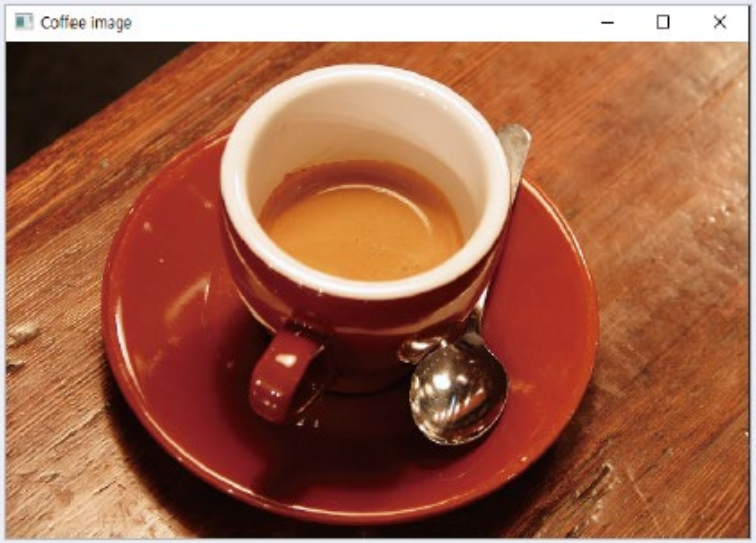

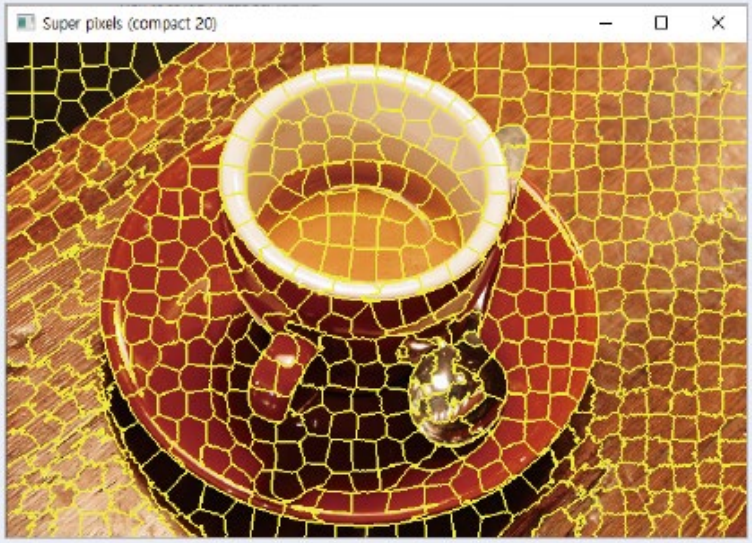

compactness=20

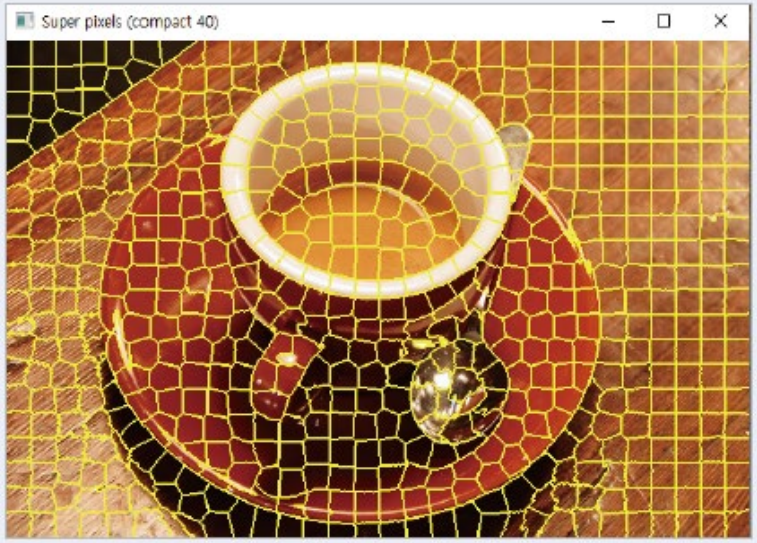

compactness=40

4.4.3 최적화 분할

- **지금까지 분할 알고리즘은 지역적 명암 변화만 살피기 때문에 한계**
  - 예) 양말의 색이 배경과 비슷하면 양말이 배경 영역에 섞임
- **전역적 정보를 고려하여 문제 해결**
  - 지역적으로 색상 변화가 약하지만 전역적으로 유리하다면 물체 경계로 간주
  - 영상을 그래프로 표현하고 최적화 알고리즘으로 분할 문제를 품

4.4.3 최적화 분할

■ 영상의 그래프 표현

- 화소 또는 슈퍼 화소를 노드로 취함
- 두 노드의 유사도를 식 (4.8)로 계산하여 에지에 부여
  - $f(v)$는 v에 해당하는 화소의 색상(r,g,b)와 위치 (x,y)를 결합한 5차원 벡터
  - v가 슈퍼 화소인 경우 화소 평균을 사용

$$
\begin{aligned}
&\text{거리} \begin{cases} d_{pq} = \left\| f(v_p) - f(v_q) \right\|, & \text{만일 } v_q \in neighbor(v_p) \\ \infty, & \text{그렇지 않으면} \end{cases} \\
&\text{유사도} \begin{cases} s_{pq} = D - d_{pq} \text{ 또는 } \dfrac{1}{e^{d_{pq}}}, & \text{만일 } v_q \in neighbor(v_p) \\ 0, & \text{그렇지 않으면} \end{cases}
\end{aligned}
\tag{4.8}
$$

4.4.3 최적화 분할

■ **정규화 절단normalized cut 알고리즘**

- cut은 영상을 두 영역으로 분할했을 때 분할의 좋은 정도를 측정해 주는 목적 함수
  - C1과 C2가 클수록 둘 사이에 에지가 많아 cut은 덩달아 커지므로 cut을 사용한 분할 알고리즘은 영역을 자잘하게 분할하는 경향

$$cut(C_1, C_2) = \sum_{v_p \in C_1, v_q \in C_2} s_{pq} \qquad (4.9)$$

- ncut은 cut을 정규화하여 영역의 크기에 중립이 되게 해줌

$$ncut(C_1, C_2) = \frac{cut(C_1, C_2)}{cut(C_1, C)} + \frac{cut(C_1, C_2)}{cut(C_2, C)} \qquad (4.10)$$

- ncut을 빨리 계산하는 효율적 알고리즘이 개발되어 있음 [Shi2000]

■ **에지 검출과 영역 분할을 결합하고 계층적으로 영역을 분할하는 알고리즘 [Arbelaez2011] 이후 별다른 발전 없음**

4.4.3 최적화 분할

프로그램 4-6 정규화 절단 알고리즘으로 영역 분할하기

```
01  import skimage
02  import numpy as np
03  import cv2 as cv
04  import time
05
06  coffee=skimage.data.coffee()
07
08  start=time.time()
09  slic=skimage.segmentation.slic(coffee,compactness=20,n_segments=600,start_
                                   label=1)
10  g=skimage.future.graph.rag_mean_color(coffee,slic,mode='similarity')
11  ncut=skimage.future.graph.cut_normalized(slic,g)  # 정규화 절단
12  print(coffee.shape,' Coffee 영상을 분할하는 데 ',time.time()-start,'초 소요')
13
14  marking=skimage.segmentation.mark_boundaries(coffee,ncut)
15  ncut_coffee=np.uint8(marking*255.0)
16
17  cv.imshow('Normalized cut',cv.cvtColor(ncut_coffee,cv.COLOR_RGB2BGR))
18
19  cv.waitKey()
20  cv.destroyAllWindows()
```

4.4.3 최적화 분할

```
(400, 600, 3) Coffee 영상을 분할하는 데 6.4380834102630615초 소요
```

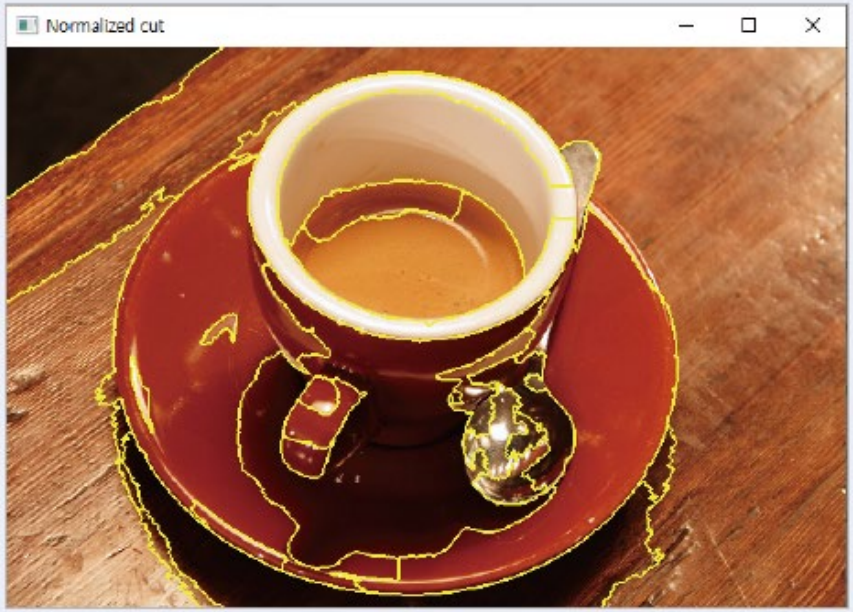

■ 고전 영역 분할 알고리즘은 색상 정보에만 의존하므로 의미 분할 불가능

- 사람은 물체의 3차원 모델과 2차원 겉모습 모델$_{\text{appearance model}}$을 동시에 사용하여 의미 분할을 수행함
- 9장에서는 딥러닝을 이용한 의미 분할을 다룸

4.5 대화식 분할

- 앞에서 다룬 분할 알고리즘은 영상 전체를 여러 개의 영역으로 분할
- 때로 한 물체의 분할에만 관심이 있는 응용이 있음
  - 예) 특정 물체를 오려내고 다른 물체로 대치
  - 사용자가 초기 정보를 입력하면 반자동 분할해주는 여러 알고리즘이 있음

4.5.1 능동 외곽선

■ 능동 외곽선active contour

- 물체 내부에 초기 곡선을 지정하면 곡선을 점점 확장하여 물체 외곽선으로 접근
- 곡선이 꿈틀대면서 에너지가 최소인 상태를 찾아가기 때문에 스네이크라는 별명

■ 곡선 표현 방법

	0	1	2	3	4	5	6	7
0	2	3	3	3	2	2	3	0
1	3	7	7 (0, 6)	7	7 (5)	5	4	0
2	3	7	7	7	7	5	4	3
3	3	6	7	7	7	5 (4)	4	3
4	3	6 (1)	7	7	6	6	4	3
5	3	6	6	6	4	4	4	3
6	3	3	4	4 (2)	4	2 (3)	2	2
7	3	3	2	2	2	2	2	2

$g(0)=(1,2)$
$g(1)=(4,1)$
$g(2)=(6,3)$
$g(3)=(6,5)$
$g(4)=(3,5)$
$g(5)=(1,4)$
$g(6)=(1,2)$

그림 4-16 디지털 공간에서 스네이크 곡선 표현

4.5.1 능동 외곽선

■ 식 (4.11)은 스네이크 곡선의 에너지를 표현

$$E(g)=\sum_{l=0}^{n}\left(e_{image}\left(g(l)\right)+e_{internal}\left(g(l)\right)+e_{domain}\left(g(l)\right)\right) \qquad (4.11)$$

■ 영역 분할을 최소 에너지를 갖는 곡선을 찾는 문제로 공식화

$$\hat{g}=\underset{g}{\operatorname{argmin}}\,E(g) \qquad (4.12)$$

■ 사용자가 지정한 초기 곡선 g_0에서 시작하여 $g_1, g_2, \cdots$로 발전해 감

4.5.1 능동 외곽선

[알고리즘 4-1] 스네이크로 물체 분할

입력: 명암 영상, 임곗값 T

출력: 최적 곡선 $\hat{g}$

```
1. 사용자 입력을 받아 초기 곡선 g를 설정한다.
2. while TRUE
3.     moved=0
4.     for i=0 to n−1
5.         for g(i)의 9개 이웃점 각각에 대해        // 자신과 8-이웃을 포함한 9개 점
6.             g(i)를 이웃점으로 이동한 곡선의 에너지 E를 식 (4.11)로 구한다.
7.         if 에너지가 최소인 점이 g(i)와 다르면
8.             g(i)를 최소점으로 이동하고 moved를 1 증가시킨다.
9.     if moved<T  // 곡선의 이동량이 임계치보다 작으면 수렴했다고 간주하고 탈출
10.        break
```

4.5.2 GrabCut

■ 네트워크 흐름network flow

- 여러 지점을 거치는 물이나 전기 흐름을 그래프로 표현하고 병목 지점을 찾아 흐름을 개선하는 문제
- Greig는 네트워크 흐름 알고리즘을 영상 복원에 적용하여 컴퓨터 비전에 끌어들임
- 이후 스테레오와 영역 분할 등에 널리 활용

■ GrabCut

- 사용자가 붓으로 물체와 배경을 초기 지정
- 붓 칠된 화소를 가지고 물체 히스토그램과 배경 히스토그램을 만듦
- 나머지 화소들은 두 히스토그램과 유사성을 따져 물체일 확률과 배경일 확률을 추정
- 이 확률 정보를 이용하여 물체 영역과 배경 영역을 갱신

4.5.2 GrabCut

프로그램 4-7 GrabCut을 이용해 물체 분할하기

```
import cv2 as cv
import numpy as np

img=cv.imread('soccer.jpg')                    # 영상 읽기
img_show=np.copy(img)                          # 붓칠을 디스플레이할 목적의 영상

mask=np.zeros((img.shape[0],img.shape[1]),np.uint8)
mask[:,:]=cv.GC_PR_BGD                         # 모든 화소를 배경일 것 같음으로 초기화

BrushSiz=9                                     # 붓의 크기
LColor,RColor=(255,0,0),(0,0,255)              # 파란색(물체)과 빨간색(배경)

def painting(event,x,y,flags,param):
    if event==cv.EVENT_LBUTTONDOWN:
        cv.circle(img_show,(x,y),BrushSiz,LColor,-1) # 왼쪽 버튼 클릭하면 파란색
        cv.circle(mask,(x,y),BrushSiz,cv.GC_FGD,-1)
    elif event==cv.EVENT_RBUTTONDOWN:
        cv.circle(img_show,(x,y),BrushSiz,RColor,-1) # 오른쪽 버튼 클릭하면 빨간색
        cv.circle(mask,(x,y),BrushSiz,cv.GC_BGD,-1)
    elif event==cv.EVENT_MOUSEMOVE and flags==cv.EVENT_FLAG_LBUTTON:
        cv.circle(img_show,(x,y),BrushSiz,LColor,-1)
                                               # 왼쪽 버튼 클릭하고 이동하면 파란색
        cv.circle(mask,(x,y),BrushSiz,cv.GC_FGD,-1)
    elif event==cv.EVENT_MOUSEMOVE and flags==cv.EVENT_FLAG_RBUTTON:
        cv.circle(img_show,(x,y),BrushSiz,RColor,-1)
                                               # 오른쪽 버튼 클릭하고 이동하면 빨간색
        cv.circle(mask,(x,y),BrushSiz,cv.GC_BGD,-1)

    cv.imshow('Painting',img_show)
```

cv.GC_FGD: 확실히 물체
cv.GC_BGD: 확실히 배경
cv.GC_PR_FGD: 물체일 것 같음
cv.GC_PR_BGD: 배경일 것 같음

4.5.2 GrabCut

```
28
29  cv.namedWindow('Painting')
30  cv.setMouseCallback('Painting',painting)
31
32  while(True):                                # 붓칠을 끝내려면 'q' 키를 누름
33      if cv.waitKey(1)==ord('q'):
34          break
35
36  # 여기부터 GrabCut 적용하는 코드
37  background=np.zeros((1,65),np.float64)   # 배경 히스토그램 0으로 초기화
38  foreground=np.zeros((1,65),np.float64)   # 물체 히스토그램 0으로 초기화
39
40  cv.grabCut(img,mask,None,background,foreground,5,cv.GC_INIT_WITH_MASK)
41  mask2=np.where((mask==cv.GC_BGD)|(mask==cv.GC_PR_BGD),0,1).astype('uint8')
42  grab=img*mask2[:,:,np.newaxis]
43  cv.imshow('Grab cut image',grab)
44
45  cv.waitKey()
46  cv.destroyAllWindows()
```

4.5.2 GrabCut

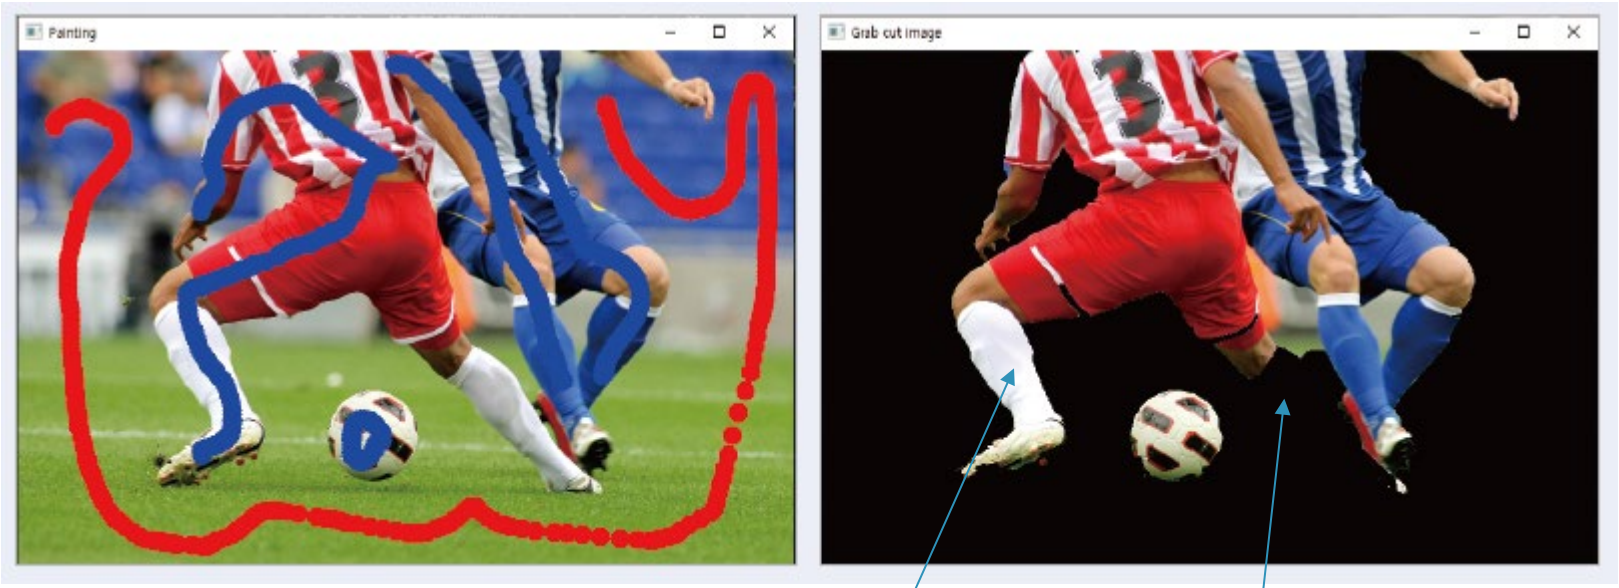

잘 분할한 곳

분할 오류

4.6 영역 특징

■ 영역의 레이블링과 기하 변환 예시

	0	1	2	3	4	5	6	7
0	1	1	1	1	1	1	1	1
1	1	2	2	2	2	3	1	1
2	2	2	2	2	3	3	1	1
3	2	2	2	3	3	3	3	1
4	1	2	2	3	3	3	3	1
5	1	2	2	2	2	3	3	1
6	1	1	2	2	2	3	1	1
7	1	1	1	1	1	1	1	1

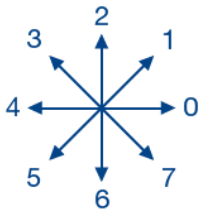

(a) 영역의 레이블링

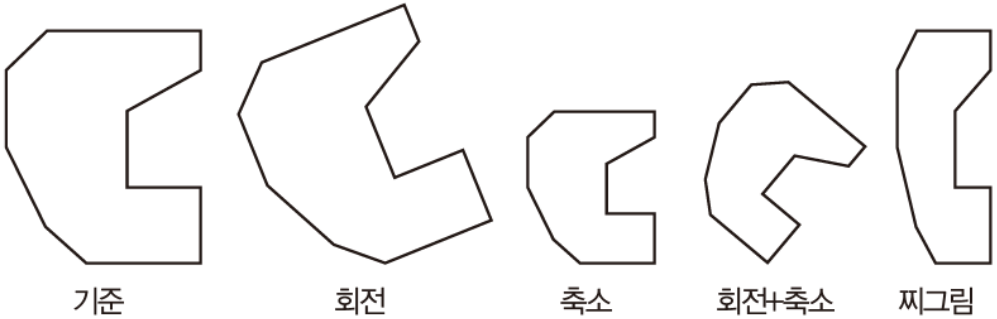

(b) 영역의 기하 변환

그림 4-17 영역의 레이블링과 기하 변환

4.6 영역 특징

■ 특징의 불변성과 등변성

- 변환을 해도 값이 변하지 않으면 불변성$_{\text{invariant}}$이 있는 특징
  - 예) 성별이라는 특징은 나이에 불변. 근력은 나이에 불변이 아님
  - 예) 면적은 회전에 불변이지만 축소에는 불변이 아님. 주축은 회전에 불변이 아니지만 축소에는 불변
- 변환에 따라 값이 따라 변하면 등변성$_{\text{equivariant}}$이 있는 특징
  - 예) 면적은 축소에 등변이지만 회전에는 등변이 아님
- 명암 변화에 둔감한 광도 불변성도 중요

■ 과업에 따라 특징을 선택하는 일이 중요

- 예) 로봇이 물체를 인식한 다음 물체를 집어야 한다면 회전에 등변인 특징을 사용해야 함

4.6 영역 특징

■ 모멘트와 모양 특징

- 영역 R의 모멘트

$$m_{qp}(R) = \sum_{(y,x)\in R} y^q x^p \qquad (4.13)$$

- 모멘트를 이용한 다양한 특징

$$\left.\begin{aligned} &\text{면적:}\ \ a = m_{00} \\ &\text{중점:}\ \ (\dot{y},\dot{x}) = \left(\frac{m_{10}}{a}, \frac{m_{01}}{a}\right) \end{aligned}\right\} \qquad (4.14)$$

$$\mu_{qp} = \sum_{(y,x)\in R} (y-\dot{y})^q (x-\dot{x})^p \qquad (4.15)$$

$$\left.\begin{aligned} &\text{열 분산:}\ \ \nu_{cc} = \frac{\mu_{20}}{a} \\ &\text{행 분산:}\ \ \nu_{rr} = \frac{\mu_{02}}{a} \\ &\text{열행 분산:}\ \ \nu_{rc} = \frac{\mu_{11}}{a} \end{aligned}\right\} \qquad (4.16)$$

$$\eta_{qp} = \frac{\mu_{qp}}{\mu_{00}^{\left(\frac{q+p}{2}+1\right)}} \qquad (4.17)$$

4.6 영역 특징

■ 영역의 둘레와 둥근 정도

$$\left.\begin{aligned} \text{둘레:}\quad & p = n_{even} + n_{odd}\sqrt{2} \\ \text{둥근 정도:}\quad & r = \frac{4\pi a}{p^2} \end{aligned}\right\} \qquad (4.18)$$

■ 주축의 방향

$$\text{주축의 방향:}\quad \theta = \frac{1}{2}\arctan\left(\frac{2\mu_{11}}{\mu_{20} - \mu_{02}}\right) \qquad (4.19)$$

4.6 영역 특징

■ 텍스처 특징. 텍스처는 일정한 패턴의 반복

- 에지 통계량으로 텍스처 특징을 측정

$$T_{edge} = \left(busy, mag(i), dir(j)\right), 0 \le i \le q-1, 0 \le j \le 7 \qquad (4.20)$$

- LBP(local binary pattern)와 LTP(local ternary pattern)
  - LBP는 중심 화소와 주위 화소의 명암 값을 비교해서 텍스처 측정. 256차원 특징 벡터
  - LTP는 작은 명암 변화에 민감한 LBP 단점 개선. 512차원 특징 벡터

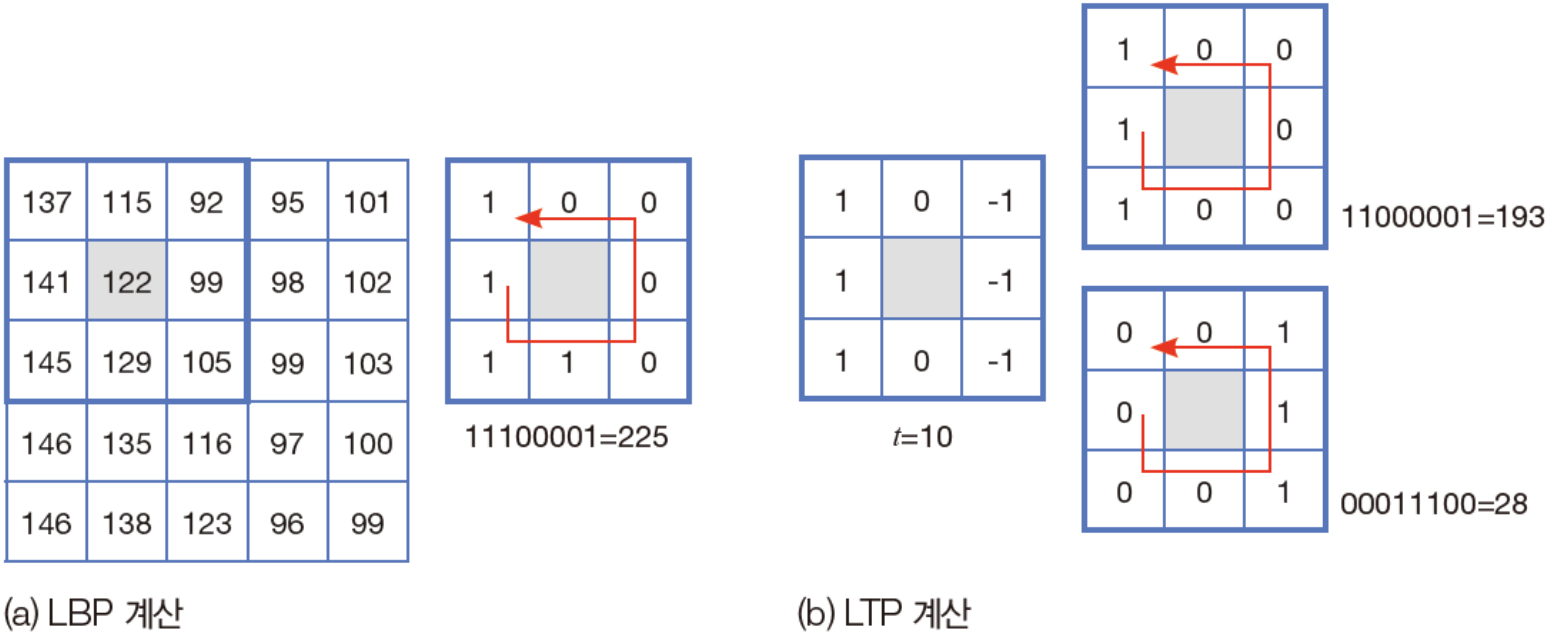

그림 4-18 LBP와 LTP 구하기

4.6 영역 특징

■ 직선 근사 알고리즘

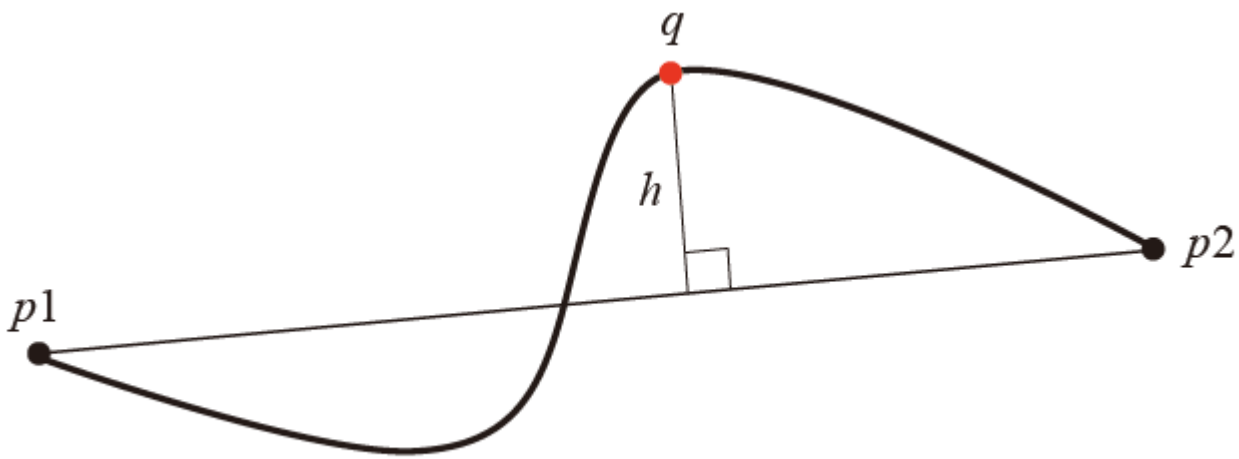

그림 4-19 직선 근사 알고리즘

4.6 영역 특징

프로그램 4-8 이진 영역의 특징을 추출하는 함수 사용하기

```
01  import skimage
02  import numpy as np
03  import cv2 as cv
04
05  orig=skimage.data.horse()
06  img=255-np.uint8(orig)*255
07  cv.imshow('Horse',img) ①
08
09  contours,hierarchy=cv.findContours(img,cv.RETR_EXTERNAL,cv.CHAIN_APPROX_NONE)
10
11  img2=cv.cvtColor(img,cv.COLOR_GRAY2BGR)            # 컬러 디스플레이용 영상
12  cv.drawContours(img2,contours,-1,(255,0,255),2)
13  cv.imshow('Horse with contour',img2) ②
14
15  contour=contours[0]
16
```

4.6 영역 특징

```
17  m=cv.moments(contour)                                  # 몇 가지 특징
18  area=cv.contourArea(contour)
19  cx,cy=m['m10']/m['m00'],m['m01']/m['m00']
20  perimeter=cv.arcLength(contour,True)
21  roundness=(4.0*np.pi*area)/(perimeter*perimeter)
22  print('면적=',area,'\n중점=(',cx,',',cy,')','\n둘레=',perimeter,'\n둥근 정도=',
        roundness) ③
23
24  img3=cv.cvtColor(img,cv.COLOR_GRAY2BGR)                # 컬러 디스플레이용 영상
25
26  contour_approx=cv.approxPolyDP(contour,8,True)         # 직선 근사
27  cv.drawContours(img3,[contour_approx],-1,(0,255,0),2)
28
29  hull=cv.convexHull(contour)                            # 볼록 헐
30  hull=hull.reshape(1,hull.shape[0],hull.shape[2])
31  cv.drawContours(img3,hull,-1,(0,0,255),2)
32
33  cv.imshow('Horse with line segments and convex hull',img3) ④
34
35  cv.waitKey()
36  cv.destroyAllWindows()
```

4.6 영역 특징

```
면적= 42390.0 ③
중점=( 187.72464024534088 , 144.43640402610677 )
둘레= 2296.7291333675385
둥근 정도= 0.1009842680321435
```

①

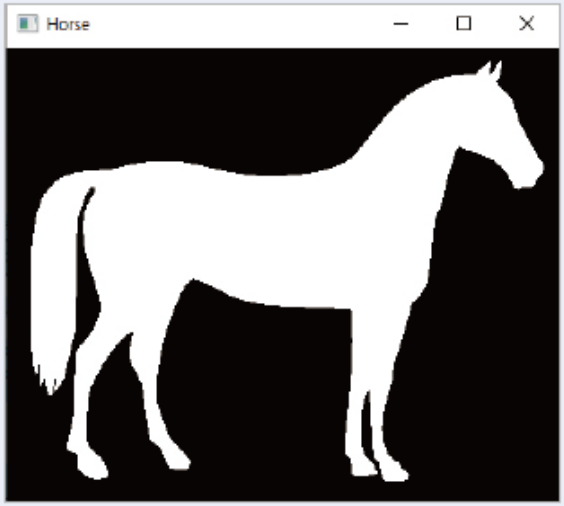

②

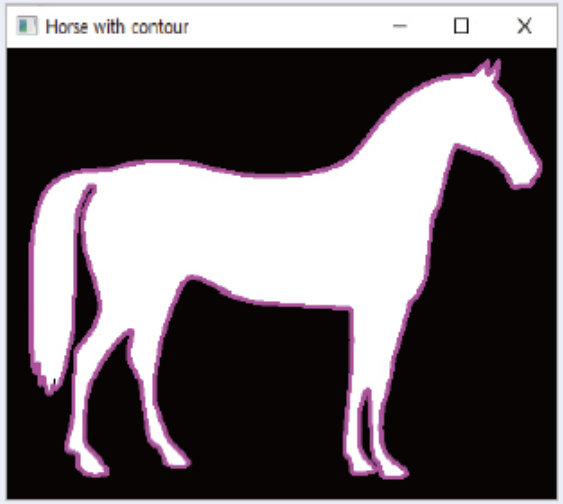

④

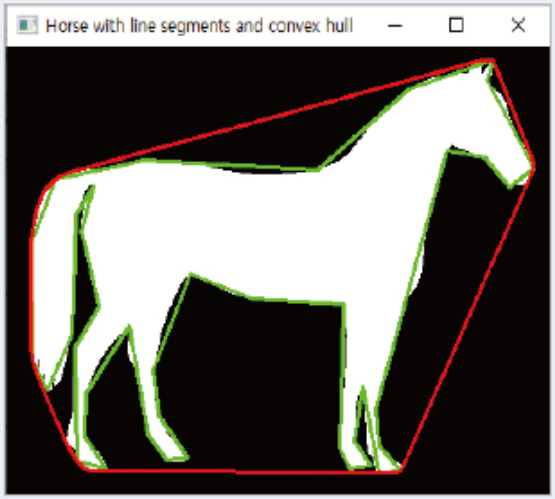

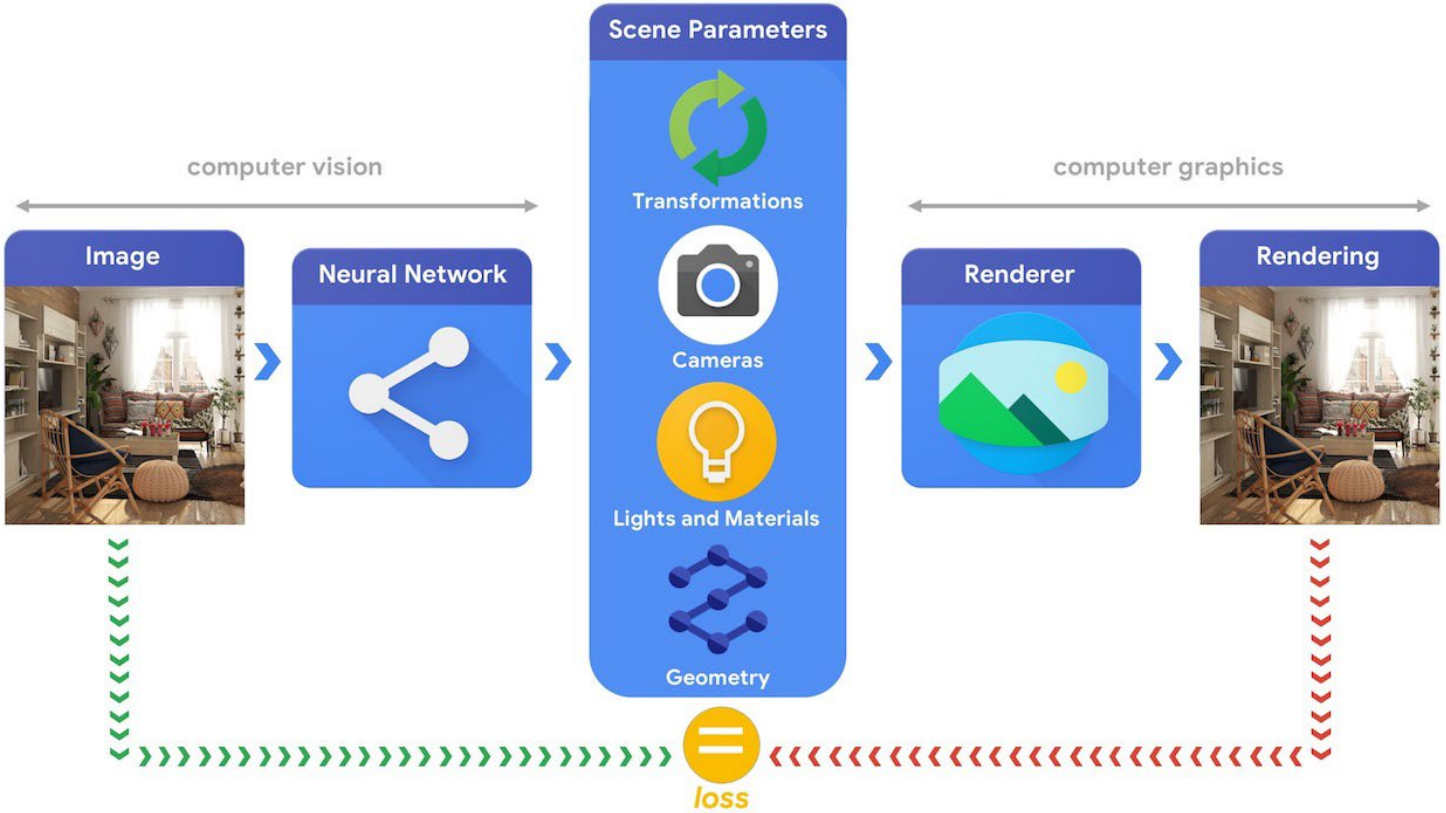
computer vision
computer graphics
Image
Neural Network
Scene Parameters
Transformations
Cameras
Lights and Materials
Geometry
Renderer
Rendering
loss

감사합니다.